

数值计算，即数值分析，是一门研究各种数学问题数值解法及其理论的学科。在实际中，当精确解析法难以求解数学问题时，数值计算发挥重要作用。它涵盖函数逼近与插值、数值积分与微分、线性方程组求解、非线性方程（组）求解以及常微分方程初值问题数值解法等方面。通过各种特定的方法，如插值法、最小二乘法、梯形法、辛普森法、高斯消元法、迭代法、牛顿法、欧拉法、龙格-库塔法等，为科学与工程领域，包括物理学、工程学、计算机科学、经济学等提供强大的解决复杂实际问题的工具，进行模拟、预测和优化。

+++info 课程章节

- CH1 数值计算方法绪论。
- CH2 插值法。
- CH3 函数逼近与曲线拟合。
- CH4 数值积分与数值微分。
- CH5 线性方程组的直接解法。
- CH6 线性方程组的迭代解法。
- CH7 非线性方程（组）的数值解法。
- CH8 常微分方程初值问题数值解法。
- CH9 深度学习中的数值问题。

## 误差

在数值计算中可能产生的误差主要有：

- 模型误差
- 观测误差
- 截断误差
- 舍入误差

在数值计算中将着重研究 [截断误差、舍入误差]{.red}，并对它们的传播与积累作出分析

### 1. 绝对误差

近似值： $x^*$ ；准确值： $x$

绝对误差：近似值与准确值之差

$$e^* = x^* - x$$

绝对误差限：误差绝对值的上界

$$\begin{aligned} |e^*| &= |x^* - x| \leq \epsilon^* \\ x &= x^* \pm \epsilon^* \end{aligned}$$

### 2. 相对误差

相对误差：误差与准确值的比值

$$e_r^* = \frac{e^*}{x} \approx \frac{e^*}{x^*} = \frac{x^* - x}{x^*}$$

相对误差限：相对误差绝对值的上界  $\epsilon_r^*$ ，即  $|e_r^*| \leq \epsilon_r^*$

$$\epsilon_r^* = \frac{\epsilon^*}{|x^*|}$$

$\epsilon^*$  是绝对误差限

### 3. 有效数字

#### 一、有效数字的定义

在数值计算中，若一个近似值  $x$  的误差限是其某一位上的 半个单位，且从该位到  $x$  的左边第一个非零数字一共有  $n$  位，则称近似值  $x$  有  $n$  位有效数字。

例如，取圆周率  $\pi$  的近似值为 3.14，它的误差限不超过 0.005，从左边第一个非零数字 3 到最后一位数字 4 一共有三位，则近似值 3.14 有三位有效数字。

#### 二、有效数字和相对误差限的关系

1. 设近似值  $x$  表示为  $x = \pm 0.a_1 a_2 \cdots a_n \times 10^m$ , 其中  $a_1, a_2, \cdots, a_n$  是 0 到 9 中的数字,  $a_1 \neq 0$ ,  $m$  为整数。若  $x$  有  $n$  位有效数字, 则其相对误差限为:

◦  $\delta \leq \frac{1}{2a_1} \times 10^{-(n-1)}$ 。

反过来, 如果已知近似值  $x$  的相对误差限满足上述条件, 也可以确定  $x$  具有  $n$  位有效数字。

2. 举例说明:

- 若近似值  $x = 0.00324$  有三位有效数字, 从左边第一个非零数字 3 开始, 到最后一位数字 4 一共有三位。此时  $a_1 = 3$ ,  $n = 3$ , 代入相对误差限公式可得:

$$\delta \leq \frac{1}{2 \times 3} \times 10^{-(3-1)} = \frac{1}{6} \times 10^{-2} = 0.00167。$$

- 若已知一个近似值的相对误差限为 0.005, 假设这个近似值为  $x = \pm 10^m \times 0.a_1 a_2 \cdots a_n \times 10^m$ , 根据相对误差限公式  $\delta \leq \frac{1}{2a_1} \times 10^{-(n-1)}$ , 当  $a_1 = 1$  时,  $0.005 = \frac{1}{2 \times 1} \times 10^{-(n-1)}$ , 通过求解可得  $n = 2$ , 即该近似值有两位有效数字。

## 4. 病态问题和条件数

### 一、病态问题

当一个数学问题的解对数据的微小变化非常敏感时, 就称这个问题为病态问题。

例如, 考虑线性方程组  $Ax = b$ , 其中  $A$  是系数矩阵,  $x$  是未知向量,  $b$  是右端项。如果系数矩阵  $A$  的微小变化会导致解  $x$  发生很大的变化, 那么这个线性方程组就是病态的。

病态问题在实际计算中会带来很大的困难, 因为数据的测量或计算过程中不可避免地会存在误差, 而对于病态问题, 这些误差可能会被极大地放大, 使得计算结果的可靠性大大降低。

### 二、条件数

条件数是用来衡量一个问题病态程度的指标。

- 对于++线性方程组++ $Ax = b$ , 矩阵  $A$  的条件数定义为  $\|A\| \|A^{-1}\|$ , 其中  $\|\cdot\|$  表示矩阵的某种范数。
  - 条件数越大, 说明问题越病态, 解对数据的微小变化就越敏感。
  - 条件数越小, 问题的病态程度就越低, 解相对比较稳定。
- 例如, 当条件数非常大时, 即使右端项  $b$  只有很小的误差, 解  $x$  可能会产生很大的误差。而当条件数较小时, 数据的微小误差对解的影响相对较小。

在数值计算中, 了解问题的病态程度是非常重要的, 可以通过分析条件数来判断问题是否病态, 并采取相应的措施来减少误差的影响, 比如使用更稳定的算法、提高数据的精度等。

矩阵为方阵且满秩则存在逆矩阵

- ++计算函数值问题的条件数++定义为: 相对误差比值  $\left| \frac{f(x) - f(x^*)}{f(x)} \right| / \left| \frac{\Delta x}{x} \right| \approx \left| \frac{x f'(x)}{f(x)} \right|$ , 记为  $C_p$ 。
- 如果条件数  $C_p$  很大, 即使自变量相对误差一般不大, 也会引起函数值相对误差很大。出现这种情况的问题被称为病态问题。
- 一般情况下, 当条件数  $C_p \geq 10$  时, 就认为是病态问题, 并且条件数越大, 病态越严重。

+++info 病态问题

- 病态问题在数值计算中会带来很大的挑战。因为在实际计算中, 数据往往存在一定的误差, 而对于病态问题, 这些误差会被极大地放大, 导致计算结果的可靠性降低。
- 为了应对病态问题, 可以采取一些措施。例如, 使用更稳定的算法、提高数据的精度、进行数据预处理以减少误差等。
- 在实际应用中, 判断一个问题是否为病态问题是非常重要的。可以通过计算条件数来初步判断问题的病态程度。如果条件数较大, 就需要更加谨慎地处理问题, 以避免误差的过度放大。
- 不同的问题可能具有不同程度的病态性。有些问题可能在特定的参数范围内是病态的, 而在其他参数范围内则是良态的。因此, 在分析问题时, 需要综合考虑各种因素, 以确定问题的病态程度。
- 除了计算函数值问题, 在其他数值计算问题中, 也可以类似地定义条件数来衡量问题的病态程度。例如, 在求解线性方程组、插值问题、数值积分等问题中, 都可以通过分析条件数来判断问题的稳定性和可靠性。

additional : 数值稳定性

# 插值

## 1. 拉格朗日插值

### 一、基本概念

给定  $n + 1$  个互异的节点  $(x_0, y_0), (x_1, y_1), \dots, (x_n, y_n)$ , 其中  $x_i$  互不相同,  $y_i$  为对应的函数值。拉格朗日插值的目的是构造一个次数不超过  $n$  的多项式  $L_n(x)$ , 使得在这些节点上,  $L_n(x_i) = y_i$ , 即多项式在给定的节点处与函数值相等。

### 二、插值多项式的形式

拉格朗日插值多项式的形式为：

$$L_n(x) = \sum_{i=0}^n y_i l_i(x)$$

其中  $L_i(x)$  为拉格朗日基函数, 定义为：

$$l_i(x) = \prod_{j=0, j \neq i}^n \frac{x - x_j}{x_i - x_j}$$

∴ info

**定义 1:** 若  $n$  次多项式  $l_j(x) (j = 0, 1, \dots, n)$  在  $n + 1$  个节点  $x_0 < x_1 < \dots < x_n$  上满足条件：

$$l_j(x_k) = \begin{cases} 1, & k = j; \\ 0, & k \neq j. \end{cases} \quad (j, k = 0, 1, \dots, n) \quad (2.7)$$

就称这  $n + 1$  个  $n$  次多项式  $l_0(x), l_1(x), \dots, l_n(x)$  为节点  $x_0, x_1, \dots, x_n$  上的  $n$  次插值基函数。

∴

### 三、计算步骤

- 确定插值节点：给定一组互异的节点  $(x_0, y_0), (x_1, y_1), \dots, (x_n, y_n)$ 。
- 计算拉格朗日基函数：对于每个  $i$ , 计算  $L_i(x)$ 。
  - 例如, 当  $n = 2$  时, 假设有三个节点  $(x_0, y_0), (x_1, y_1), (x_2, y_2)$ , 则：
    - $l_0(x) = \frac{(x-x_1)(x-x_2)}{(x_0-x_1)(x_0-x_2)}$ ;
    - $l_1(x) = \frac{(x-x_0)(x-x_2)}{(x_1-x_0)(x_1-x_2)}$ ;
    - $l_2(x) = \frac{(x-x_0)(x-x_1)}{(x_2-x_0)(x_2-x_1)}$ 。
- 计算插值多项式：将节点的函数值  $y_i$  和对应的基函数  $L_i(x)$  代入插值多项式公式, 得到  $L_n(x) = \sum_{i=0}^n y_i l_i(x)$ 。

### 四、特点和应用

- 特点：
  - 拉格朗日插值多项式在节点处与给定的函数值完全相等, 具有较高的精度。
  - ++当节点增加时, 需要重新计算整个插值多项式, 计算量较大++。
  - 对于高次插值, 可能会出现龙格现象, 即在插值区间的两端, 插值多项式的波动较大, 与原函数的差异较大。
- 应用：
  - 函数逼近：可以用拉格朗日插值多项式来逼近一个未知的函数。
  - 数据拟合：当只有离散的数据点时, 可以通过拉格朗日插值得到一个连续的函数表达式。
  - 数值积分和数值微分：可以利用插值多项式进行数值积分和数值微分的计算。

+++primary 例题

假设有三个数据点  $(1, 2)$ 、 $(2, 5)$ 、 $(3, 10)$ , 要求通过拉格朗日插值法构造一个插值多项式来逼近函数关系。

- 首先确定插值基函数：
  - 对于三个节点,  $n = 2$ 。
  - 当  $j = 0$  时,  $x_0 = 1$ , 对应的基函数  $l_0(x) = \frac{(x-x_1)(x-x_2)}{(x_0-x_1)(x_0-x_2)} = \frac{(x-2)(x-3)}{(1-2)(1-3)} = \frac{(x-2)(x-3)}{2}$ 。
  - 当  $j = 1$  时,  $x_1 = 2$ , 对应的基函数  $l_1(x) = \frac{(x-x_0)(x-x_2)}{(x_1-x_0)(x_1-x_2)} = \frac{(x-1)(x-3)}{(2-1)(2-3)} = (x-1)(x-3)$ 。
  - 当  $j = 2$  时,  $x_2 = 3$ , 对应的基函数  $l_2(x) = \frac{(x-x_0)(x-x_1)}{(x_2-x_0)(x_2-x_1)} = \frac{(x-1)(x-2)}{(3-1)(3-2)} = \frac{(x-1)(x-2)}{2}$ 。
- 然后构造插值多项式：
  - 插值多项式为

$$L_2(x) = y_0 l_0(x) + y_1 l_1(x) + y_2 l_2(x)$$

- 已知  $y_0 = 2, y_1 = 5, y_2 = 10$ . 则

$$L_2(x) = 2 \times \frac{(x-2)(x-3)}{2} + 5 \times (x-1)(x-3) + 10 \times \frac{(x-1)(x-2)}{2}.$$

- 化简可得:  $L_2(x) = x^2 + 2x - 1$ . 这个插值多项式  $L_2(x)$  在给定的三个节点处与函数值相等, 即  $L_2(1) = 2, L_2(2) = 5, L_2(3) = 10$ . 它可以用来逼近这三个数据点所代表的函数关系。
- 事实上如果这是一个 2 次函数, 则二次拉格朗日插值得到的就是 [原函数](#)。

在拉格朗日插值中, 利用余项表达式 (2.12) 可知, 若被插函数  $f(x) \in H_n$ , 由于  $f^{(n+1)}(x) = 0$ , 故  $R_n(x) = f(x) - L_n(x) = 0$ , 即它的插值多项式  $L_n(x) = f(x)$ 。

在拉格朗日插值中, 插值余项与误差估计是评估插值效果的重要指标。

## 五、插值余项

若在区间  $[a, b]$  上用  $L_n(x)$  近似  $f(x)$ , 则截断误差  $R_n(x) = f(x) - L_n(x)$  被称为插值多项式的余项。

## 六、误差估计

**[定理 2]**: 设  $f^{(n)}(x)$  在  $[a, b]$  上连续,  $f^{(n+1)}(x)$  在  $(a, b)$  内存在, 节点  $a \leq x_0 < x_1 < \dots < x_n \leq b$ ,  $L_n(x)$  是满足特定条件的插值多项式, 则对任何  $x \in [a, b]$ , 插值余项

$$R_n(x) = f(x) - L_n(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!} \omega_{n+1}(x).$$

这里  $\xi \in (a, b)$  且依赖于  $x$ ,  $\omega_{n+1}(x) = \prod_{j=0}^n (x - x_j)$ .

- 这个公式可以用来估计插值的误差。当  $f^{(n+1)}(x)$  在区间上有界时, 可以通过余项公式得到误差的上界。

- 例如, 如果能确定  $f^{(n+1)}(x)$  的一个上界  $M$ , 即对于所有的  $x \in (a, b)$ , 有

$$|f^{(n+1)}(x)| \leq M$$

那么误差

$$|R_n(x)| = \left| \frac{f^{(n+1)}(\xi)}{(n+1)!} \omega_{n+1}(x) \right| \leq \frac{M}{(n+1)!} |\omega_{n+1}(x)|.$$

- 从误差估计可以看出以下几点:

- 插值多项式的次数  $n$  越高, 理论上误差可能会越小。因为分母  $(n+1)!$  随着  $n$  的增大而增大。
- 然而, 在实际应用中, 高次插值并不一定总是能得到更好的结果。这是因为高次插值可能会出现龙格现象, 即在插值区间的两端, 插值多项式的波动较大, 与原函数的差异较大。
- 插值节点的分布也会影响误差。如果插值节点分布不均匀或者过于密集, 可能会导致误差增大。

# 2. 差商

## 一、定义

设有函数  $f(x)$  以及一系列互不相等的点  $x_0, x_1, \dots, x_n$ , 则  $f$  在这些点处的一阶差商定义为:

$$f[x_i, x_{i+1}] = \frac{f(x_{i+1}) - f(x_i)}{x_{i+1} - x_i}$$

二阶差商定义为:

$$f[x_i, x_{i+1}, x_{i+2}] = \frac{f[x_{i+1}, x_{i+2}] - f[x_i, x_{i+1}]}{x_{i+2} - x_i}$$

以此类推,  $n$  阶差商定义为:

$$f[x_0, x_1, \dots, x_n] = \frac{f[x_1, x_2, \dots, x_n] - f[x_0, x_1, \dots, x_{n-1}]}{x_n - x_0}$$

## 二、性质

- 对称性: 差商的值与节点的顺序无关。即对于任意的置换  $\sigma$ , 有  $f[x_{\sigma(0)}, x_{\sigma(1)}, \dots, x_{\sigma(n)}] = f[x_0, x_1, \dots, x_n]$ 。
- 可通过 **差商表** 计算: 可以通过构造差商表来方便地计算高阶差商。差商表是一个二维表格, 其中第一列是节点, 其余列是对应节点的差商。从低阶到高阶逐步计算差商, 可以提高计算效率。
- 若  $f(x)$  在  $[a, b]$  上存在  $n$  阶导数, 且节点  $x_0, x_1, \dots, x_n \in [a, b]$ , 则  $n$  阶均差与导数关系如下:

$$f[x_0, x_1, \dots, x_n] = \frac{f^{(n)}(\xi)}{n!}, \quad \xi \in [a, b].$$

这公式可直接用罗尔定理证明。

设  $q(x) = f[x, x_0, \cdots, x_n](x - x_0)(x - x_1) \cdots (x - x_n)$ ,  $q(x)$

在  $x_0, \cdots, x_n$  处均为零, 所以  $q(x)$  在  $[a, b]$  上有  $n + 1$  个零点。

根据罗尔定理,  $q'(x)$  在  $q(x)$  的两个零点间至少有一个零点, 故  $q'(x)$  在  $[a, b]$  内至少有  $n$  个零点; 反复应用罗尔定理, 可知  $q^{(n)}(x)$  在  $[a, b]$  内至少有 1 个零点, 记为  $\xi \in [a, b]$ , 使

$q^{(n)}(\xi) = f^{(n)}(\xi) - n!f[x_0, \cdots, x_n] = 0$ ,

所以  $f[x_0, \cdots, x_n] = \frac{f^{(n)}(\xi)}{n!}$ 。

三、应用

1. 牛顿插值: 差商在牛顿插值法中起着关键作用。牛顿插值多项式的形式为:
- $$N_n(x) = f(x_0) + f[x_0, x_1](x - x_0) + f[x_0, x_1, x_2](x - x_0)(x - x_1) + \cdots + f[x_0, x_1, \cdots, x_n](x - x_0)(x - x_1) \cdots (x - x_{n-1})$$
- 通过差商可以确定插值多项式的系数, 从而实现对函数的逼近。
2. 数值微分: 可以利用差商来近似计算函数的导数。例如, 一阶导数可以近似为一阶差商, 即  $f'(x) \approx \frac{f(x+h)-f(x)}{h}$ , 其中  $h$  是一个小的增量。

四、差商表计算

以下是升序下标的差商表示例:

$x_k$	$f(x_k)$	一阶差商	二阶差商	三阶差商	四阶差商	...	$n$ 阶差商
$x_0$	$f(x_0)$					...	
$x_1$	$f(x_1)$	$f[x_0, x_1]$				...	
$x_2$	$f(x_2)$	$f[x_1, x_2]$	$f[x_0, x_1, x_2]$			...	
$x_3$	$f(x_3)$	$f[x_2, x_3]$	$f[x_1, x_2, x_3]$	$f[x_0, x_1, x_2, x_3]$		...	
$x_4$	$f(x_4)$	$f[x_3, x_4]$	$f[x_2, x_3, x_4]$	$f[x_1, x_2, x_3, x_4]$	$f[x_0, x_1, x_2, x_3, x_4]$	...	
...	...	...	...	...	...	...	...
$x_n$	$f(x_n)$	$f[x_{n-1}, x_n]$	$f[x_{n-2}, x_{n-1}, x_n]$	$f[x_{n-3}, x_{n-2}, x_{n-1}, x_n]$	$f[x_{n-4}, x_{n-3}, x_{n-2}, x_{n-1}, x_n]$	...	$f[x_0, x_1, \cdots, x_n]$

其中一阶差商计算公式为:

$f[x_i, x_{i+1}] = \frac{f(x_{i+1})-f(x_i)}{x_{i+1}-x_i};$

二阶差商计算公式为:  $f[x_i, x_{i+1}, x_{i+2}] = \frac{f[x_{i+1}, x_{i+2}]-f[x_i, x_{i+1}]}{x_{i+2}-x_i},$

以此类推,  $n$  阶差商计算公式为:  $f[x_0, x_1, \cdots, x_n] = \frac{f[x_1, x_2, \cdots, x_n]-f[x_0, x_1, \cdots, x_{n-1}]}{x_n-x_0}。$

3. 牛顿插值

牛顿插值法是一种数值插值方法, 它通过差商来构建插值多项式。与拉格朗日插值法不同, 牛顿插值法在增加新的插值节点时, ++不需要重新计算整个插值多项式, 只需要计算新节点对应的差商项并加入到原有的多项式中即可++。

1. 牛顿插值多项式的形式
- 设给定  $n + 1$  个互异的节点  $(x_0, y_0), (x_1, y_1), \cdots, (x_n, y_n)$ , **牛顿插值多项式** 为:

$$N_n(x) = f(x_0) + f[x_0, x_1](x - x_0) + f[x_0, x_1, x_2](x - x_0)(x - x_1) + \cdots + f[x_0, x_1, \cdots, x_n](x - x_0)(x - x_1) \cdots (x - x_{n-1})$$
2. 牛顿插值法的步骤
- 首先计算差商表: 从一阶差商开始, 逐步计算高阶差商, 形成一个差商表。
  - 然后根据差商表中的数据构建牛顿插值多项式: 从最低阶的项开始, 依次加入高阶差商项, 直到得到所需的插值多项式。

[以下是通过差商表达式迭代推出牛顿插值公式的过程]{.red}:

1. 首先从一阶差商开始:
- 已知  $f[x, x_0] = \frac{f(x)-f(x_0)}{x-x_0}$ , 变形可得  $f(x) = f(x_0) + f[x, x_0](x - x_0)。$
2. 接着引入二阶差商:
- $f[x, x_0, x_1] = \frac{f[x, x_0]-f[x_0, x_1]}{x-x_1}$ , 将  $f[x, x_0] = \frac{f(x)-f(x_0)}{x-x_0}$  代入可得:

- $f[x, x_0, x_1] = \frac{\frac{f(x)-f(x_0)}{x-x_0}-f[x_0, x_1]}{x-x_1} = \frac{f(x)-f(x_0)-(x-x_0)f[x_0, x_1]}{(x-x_0)(x-x_1)}。$
- 进一步变形得到  $f(x) = f(x_0) + f[x_0, x_1](x - x_0) + f[x, x_0, x_1](x - x_0)(x - x_1)。$

3. 然后引入三阶差商：

- $f[x, x_0, x_1, x_2] = \frac{f[x, x_0, x_1]-f[x_0, x_1, x_2]}{x-x_2}$ ，把前面得到的  $f[x, x_0, x_1]$  表达式代入可得：
  - $f[x, x_0, x_1, x_2] = \frac{\frac{f(x)-f(x_0)-(x-x_0)f[x_0, x_1]}{(x-x_0)(x-x_1)}-f[x_0, x_1, x_2]}{x-x_2} = \frac{f(x)-f(x_0)-(x-x_0)f[x_0, x_1]-(x-x_0)(x-x_1)f[x_0, x_1, x_2]}{(x-x_0)(x-x_1)(x-x_2)}。$
  - 进而得到
- $$f(x) = f(x_0) + f[x_0, x_1](x - x_0) + f[x_0, x_1, x_2](x - x_0)(x - x_1) + f[x, x_0, x_1, x_2](x - x_0)(x - x_1)(x - x_2)。$$

4. 以此类推：

- 最终可以得到牛顿插值公式

$$N_n(x) = f(x_0) + f[x_0, x_1](x - x_0) + f[x_0, x_1, x_2](x - x_0)(x - x_1) + \cdots + f[x_0, x_1, \cdots, x_n](x - x_0)(x - x_1) \cdots (x - x_{n-1})$$

已知三个数据点 (1, 2)、(2, 5)、(3, 10)，求牛顿插值多项式。

1. 计算差商表：

- 首先列出数据点：

$x$	$y$
1	2
2	5
3	10

- 计算一阶差商：

- $f[x_0, x_1] = \frac{f(x_1)-f(x_0)}{x_1-x_0} = \frac{5-2}{2-1} = 3。$
- $f[x_1, x_2] = \frac{f(x_2)-f(x_1)}{x_2-x_1} = \frac{10-5}{3-2} = 5。$

- 计算二阶差商：

- $f[x_0, x_1, x_2] = \frac{f[x_1, x_2]-f[x_0, x_1]}{x_2-x_0} = \frac{5-3}{3-1} = 1。$

差商表如下：

$x$	$y$	一阶差商	二阶差商
$x_0 = 1$	$y_0 = 2$		
$x_1 = 2$	$y_1 = 5$	$f[x_0, x_1] = 3$	
$x_2 = 3$	$y_2 = 10$	$f[x_1, x_2] = 5$	$f[x_0, x_1, x_2] = \frac{f[x_1, x_2]-f[x_0, x_1]}{x_2-x_0} = 1$

2. 构建牛顿插值多项式：

- 根据差商表，牛顿插值多项式为：

$$N_2(x) = f(x_0) + f[x_0, x_1](x - x_0) + f[x_0, x_1, x_2](x - x_0)(x - x_1)$$

- 代入数据点的值和差商：

$$N_2(x) = 2 + 3(x - 1) + 1(x - 1)(x - 2)$$

- 化简得：

$$N_2(x) = 2 + 3x - 3 + x^2 - 3x + 2 = x^2 + 1$$

所以，对于给定的三个数据点，牛顿插值多项式为  $N_2(x) = x^2 + 1。$

## 4. 差分

以下是对上述内容的总结：

### 一、等距节点下的牛顿插值公式简化

在实际应用中常遇到等距节点的情形，即  $x_k = x_0 + kh$  ( $k = 0, 1, \cdots, n$ )，其中  $h$  为常数步长。此时插值公式可以进一步简化且计算更简单。

### 二、差分的定义与计算

- 对于等距节点, 设  $x_k$  点的函数值为  $f_k = f(x_k)$ 。
  - 称  $\Delta f_k = f_{k+1} - f_k$  为  $x_k$  处以  $h$  为步长的一阶 (向前) 差分。
  - 类似地,  $\Delta^2 f_k = \Delta f_{k+1} - \Delta f_k$  为  $x_k$  处的二阶差分。
  - 一般地,  $\Delta^n f_k = \Delta^{n-1} f_{k+1} - \Delta^{n-1} f_k$  为  $x_k$  处的  $n$  阶差分。

### 三、引入算子符号

为了表示方便, 引入两个常用算子符号:

- $I$  为不变算子,  $If_k = f_k$ 。
- $E$  为步长为  $h$  的移位算子,  $Ef_k = f_{k+1}$ 。

由此可得

$$\Delta f_k = Ef_k - If_k = (E - I)f_k$$

进一步有

$$\Delta^n f_k = (E - I)^n f_k = \sum_{j=0}^n (-1)^j \binom{n}{j} E^{n-j} f_k = \sum_{j=0}^n (-1)^j \binom{n}{j} f_{n+k-j}$$

- 其中  $\binom{n}{j} = \frac{n(n-1)\cdots(n-j+1)}{j!}$  为二项式展开系数。

另{.red}

$$f_{n+k} = E^n f_k = (I + \Delta)^n f_k = \left[ \sum_{j=0}^n \binom{n}{j} \Delta^j \right] f_k$$

$$f[x_k, x_{k+1}] = \frac{f_{k+1} - f_k}{x_{k+1} - x_k} = \frac{\Delta f_k}{h}$$

$$f[x_k, x_{k+1}, x_{k+2}] = \frac{f[x_{k+1}, x_{k+2}] - f[x_k, x_{k+1}]}{x_{k+2} - x_k} = \frac{1}{2h^2} \Delta^2 f_k$$

### 四、差分与差商的关系及与导数的关系

1. 一般地有

$$f[x_k, \dots, x_{k+m}] = \frac{1}{m!} \frac{1}{h^m} \Delta^m f_k$$

2. 由上述关系和前面的公式又可得到差分与导数的关系:

$$\Delta^n f_k = h^n f^{(n)}(\xi)$$

其中  $\xi \in (x_k, x_{k+n})$ 。

∴ primary

牛顿前插公式可以简单的理解为将 等距均差/差商 替换为 前向差分

∴

## 5. 分段插值

# 函数逼近

- 插值：在节点处函数值相等
- 拟合：在数据点处误差平方和最小

## 1. 内积空间

### 一、定义

设  $C[a, b]$  是区间  $[a, b]$  上所有连续函数构成的集合。对于任意的  $f(x), g(x) \in C[a, b]$ ，定义内积为：
$$(f, g) = \int_a^b f(x)g(x)dx。$$

在这个定义下， $C[a, b]$  构成一个内积空间。

### 二、性质

1. 对称性： $(f, g) = \overline{(g, f)}$ ，其中  $\overline{(g, f)}$  表示  $(g, f)$  的共轭。对于实函数，即  $(f, g) = (g, f)$ 。
2. 线性性：对于任意的函数  $f(x), g(x), h(x) \in C[a, b]$  和实数  $\alpha, \beta$ ，有  $(\alpha f + \beta g, h) = \alpha(f, h) + \beta(g, h)$ 。
3. 正定性： $(f, f) \geq 0$ ，且  $(f, f) = 0$  当且仅当  $f(x) = 0$ 。

在数值计算中，函数的范数是一个重要的概念。

## 2. 范数

### 一、定义

设  $f(x)$  是定义在区间  $[a, b]$  上的函数，函数的范数通常有以下几种定义：

1.  $L_p$  范数：
  - 对于  $p \geq 1$ ， $f(x)$  的  $L_p$  范数定义为  $\|f\|_{L_p} = \left( \int_a^b |f(x)|^p dx \right)^{\frac{1}{p}}$ 。
  - 当  $p = 2$  时，称为  $L_2$  范数，也记为  $\|f\|_2 = \sqrt{\int_a^b f(x)^2 dx}$ 。
2. 无穷范数：
  - $f(x)$  的无穷范数定义为  $\|f\|_{\infty} = \max_{a \leq x \leq b} |f(x)|$ 。

### 二、性质

1. 正定性：对于任意函数  $f(x)$ ， $\|f\| \geq 0$ ，且  $\|f\| = 0$  当且仅当  $f(x) = 0$ 。
2. 齐次性：对于任意实数  $\alpha$  和函数  $f(x)$ ， $\|\alpha f\| = |\alpha| \|f\|$ 。
3. 三角不等式：对于任意函数  $f(x)$  和  $g(x)$ ， $\|f + g\| \leq \|f\| + \|g\|$ 。
4. 平行四边形定理： $\|f + g\|_2^2 + \|f - g\|_2^2 = 2(\|f\|_2^2 + \|g\|_2^2)$ 。

+++primary 证明如下：

1. 首先计算  $\|f + g\|_2^2$ ：

$$\|f + g\|_2^2 = \int_a^b (f(x) + g(x))^2 dx = \int_a^b (f(x)^2 + 2f(x)g(x) + g(x)^2) dx = \int_a^b f(x)^2 dx + \int_a^b 2f(x)g(x) dx + \int_a^b g(x)^2 dx = \|f\|_2^2 + 2 \int_a^b f(x)g(x) dx + \|g\|_2^2$$

5. 接着计算  $\|f - g\|_2^2$ ：

$$\|f - g\|_2^2 = \int_a^b (f(x) - g(x))^2 dx = \int_a^b (f(x)^2 - 2f(x)g(x) + g(x)^2) dx = \int_a^b f(x)^2 dx - \int_a^b 2f(x)g(x) dx + \int_a^b g(x)^2 dx = \|f\|_2^2 - 2 \int_a^b f(x)g(x) dx + \|g\|_2^2$$

6. 最后计算  $\|f + g\|_2^2 + \|f - g\|_2^2$

$$\|f + g\|_2^2 + \|f - g\|_2^2 = (\|f\|_2^2 + 2 \int_a^b f(x)g(x) dx + \|g\|_2^2) + (\|f\|_2^2 - 2 \int_a^b f(x)g(x) dx + \|g\|_2^2) = 2(\|f\|_2^2 + \|g\|_2^2)$$

## 2.1 向量矩阵

### 一、向量范数

1. 定义：
  - 对于一个  $n$  维向量  $\mathbf{x} = (x_1, x_2, \dots, x_n)$ ，向量范数是一个非负实数  $\|\mathbf{x}\|$ ，满足以下三个性质：
    - 正定性： $\|\mathbf{x}\| \geq 0$ ，且  $\|\mathbf{x}\| = 0$  当且仅当  $\mathbf{x} = \mathbf{0}$ 。
    - 齐次性：对于任意实数  $\alpha$ ，有  $\|\alpha \mathbf{x}\| = |\alpha| \|\mathbf{x}\|$ 。
    - 三角不等式：对于任意两个向量  $\mathbf{x}$  和  $\mathbf{y}$ ，有  $\|\mathbf{x} + \mathbf{y}\| \leq \|\mathbf{x}\| + \|\mathbf{y}\|$ 。
2. 常见的向量范数：



- $p$ -范数:  $\|\boldsymbol{x}\|_p = (\sum_{i=1}^n |x_i|^p)^{\frac{1}{p}}$ , 其中  $p \geq 1$ 。当  $p = 2$  时, 称为欧几里得范数或 2-范数,  $\|\boldsymbol{x}\|_2 = \sqrt{\sum_{i=1}^n x_i^2}$ 。
- 1-范数:  $\|\boldsymbol{x}\|_1 = \sum_{i=1}^n |x_i|$ 。
- $\infty$ -范数:  $\|\boldsymbol{x}\|_\infty = \max_{1 \leq i \leq n} |x_i|$ 。

3. 应用:

- 用于衡量向量的大小和长度, 在数值分析、优化问题、机器学习等领域有广泛应用。例如, 在优化算法中, 向量范数可以用来衡量迭代过程中解的变化程度。

## 二、矩阵范数

1. 定义:

- 对于一个  $m \times n$  的矩阵  $\boldsymbol{A}$ , 矩阵范数是一个非负实数  $\|\boldsymbol{A}\|$ , 满足以下四个性质:
  - 正定性:  $\|\boldsymbol{A}\| \geq 0$ , 且  $\|\boldsymbol{A}\| = 0$  当且仅当  $\boldsymbol{A} = \mathbf{0}$ 。
  - 齐次性: 对于任意实数  $\alpha$ , 有  $\|\alpha \boldsymbol{A}\| = |\alpha| \|\boldsymbol{A}\|$ 。
  - 三角不等式: 对于任意两个矩阵  $\boldsymbol{A}$  和  $\boldsymbol{B}$ , 有  $\|\boldsymbol{A} + \boldsymbol{B}\| \leq \|\boldsymbol{A}\| + \|\boldsymbol{B}\|$ 。
  - 相容性: 对于任意两个矩阵  $\boldsymbol{A}$  和  $\boldsymbol{B}$ , 有  $\|\boldsymbol{AB}\| \leq \|\boldsymbol{A}\| \|\boldsymbol{B}\|$ 。

2. 常见的矩阵范数:

- Frobenius 范数:  $\|\boldsymbol{A}\|_F = \sqrt{\sum_{i=1}^m \sum_{j=1}^n |a_{ij}|^2}$ , 其中  $a_{ij}$  是矩阵  $\boldsymbol{A}$  的第  $i$  行第  $j$  列元素。
- 诱导范数: 由向量范数诱导而来, 对于给定的向量范数  $\|\cdot\|$ , 矩阵  $\boldsymbol{A}$  的诱导范数定义为  $\|\boldsymbol{A}\| = \max_{\boldsymbol{x} \neq \mathbf{0}} \frac{\|\boldsymbol{Ax}\|}{\|\boldsymbol{x}\|}$ 。例如, 由 2-范数诱导的矩阵范数也称为谱范数,  $\|\boldsymbol{A}\|_2 = \sqrt{\lambda_{\max}(\boldsymbol{A}^T \boldsymbol{A})}$ , 其中  $\lambda_{\max}(\boldsymbol{A}^T \boldsymbol{A})$  表示矩阵  $\boldsymbol{A}^T \boldsymbol{A}$  的最大特征值。

## 3. 正交

在数值计算中, 带权正交是内积空间中一种特殊的正交关系。

### 一、定义

设  $C[a, b]$  是区间  $[a, b]$  上所有连续函数构成的内积空间, 对于任意的  $f(x), g(x) \in C[a, b]$ , 定义带权内积为  $(f, g)_w = \int_a^b w(x) f(x) g(x) dx$ , 其中  $w(x)$  是一个在区间  $[a, b]$  上的非负函数, 称为权函数。

如果两个函数  $f(x)$  和  $g(x)$  满足  $(f, g)_w = 0$ , 则称函数  $f(x)$  与  $g(x)$  在带权内积空间中带权  $w(x)$  正交。

### 二、举例

例如, 在区间  $[-1, 1]$  上, 取权函数  $w(x) = 1 - x^2$ , 函数  $f(x) = x$ ,  $g(x) = x^2$ 。

$$(f, g)_w = \int_{-1}^1 (1 - x^2) x \cdot x^2 dx = \int_{-1}^1 (x^3 - x^5) dx = \left[ \frac{x^4}{4} - \frac{x^6}{6} \right]_{-1}^1 = \frac{1}{4} - \frac{1}{6} - \left( \frac{1}{4} - \frac{1}{6} \right) = 0。$$

所以在这个带权内积空间中, 函数  $x$  与函数  $x^2$  带权  $w(x)$  正交。

### 三、性质

1. 性质:

- 带权正交也具有类似普通正交的一些性质, 如对称性 (若  $f$  与  $g$  带权正交, 则  $g$  与  $f$  也带权正交)、线性性 (若  $f_1$  与  $g$  带权正交,  $f_2$  与  $g$  带权正交, 则  $\alpha f_1 + \beta f_2$  与  $g$  也带权正交, 其中  $\alpha, \beta$  为实数) 等。
- 零函数与任何函数在带权内积空间中都带权正交。

## 4. 最佳一致逼近

最佳一致逼近是数值分析中的一个重要概念。

### 一、基本概念

1. 设  $f(x) \in C[a, b]$ , 即  $f(x)$  是区间  $[a, b]$  上的连续函数。  $p_n(x) \in H_n$ , 其中  $H_n$  是次数不超过  $n$  的多项式集合。

$$\Delta(f, p_n) = \|f - p_n\|_\infty = \max_{a \leq x \leq b} |f(x) - p_n(x)|$$

被称为  $f(x)$  与  $p_n(x)$  在  $[a, b]$  上的偏差。

这个偏差衡量了多项式  $p_n(x)$  与函数  $f(x)$  在区间  $[a, b]$  上的++最大差异程度++。

$$E_n = \inf_{p_n \in H_n} \{\Delta(f, p_n)\} = \inf_{p_n \in H_n} \max_{a \leq x \leq b} |f(x) - p_n(x)|$$

称为  $f(x)$  在  $[a, b]$  上的最小偏差。也就是要在所有次数不超过  $n$  的多项式中, 找到与  $f(x)$  偏差最小的那个值。

2. 若存在  $p_n^*(x) \in H_n$ , 使得  $\Delta(f, p_n^*) = E_n$ , 则称  $p_n^*(x)$  是  $f(x)$  在  $[a, b]$  上的  $n$  次最佳一致逼近多项式, 也称为最小偏差逼近多项式或最佳逼近多项式。它是在次数不超过  $n$  的多项式中最接近函数  $f(x)$  的那个多项式。

## 5. 最佳平方逼近

最佳平方逼近是一种重要的函数逼近方法。

### 一、基本概念

1. 对于函数  $f(x) \in C[a, b]$ , 如果存在一个  $n$  次多项式  $s^*(x) = \sum_{j=0}^n a_j \varphi_j$  (其中  $\varphi_j$  是一组基函数), 使得

$$\int_a^b [f(x) - s^*(x)]^2 dx = \min_{s(x) \in H_n} \int_a^b [f(x) - s(x)]^2 dx$$

那么称  $s^*(x)$  为  $f(x)$  在区间  $[a, b]$  上的  $n$  次最佳平方逼近多项式。

- 这里的目标是找到一个多项式, 使得它与原函数  $f(x)$  在区间  $[a, b]$  上的 **平方误差积分** 最小。

2. 若  $f(x) \in C[a, b]$ ,  $\Phi = \text{span}\{\varphi_0, \dots, \varphi_n\} \subset C[a, b]$ , 存在  $s^*(x) \in \Phi$  满足

$$\int_a^b \rho(x)[f(x) - s^*(x)]^2 dx = \min_{s(x) \in \Phi} \int_a^b \rho(x)[f(x) - s(x)]^2 dx$$

则称  $s^*(x)$  为函数  $f(x)$  在集合  $\Phi$  上的最佳平方逼近函数。

- 这里引入了权函数  $\rho(x)$ , 可以根据不同的需求对不同点的误差进行加权。

### 二、求解方法

1. 问题归结为 **求系数**  $a_j$  使得

$$I(a_0, \dots, a_n) = \int_a^b \rho(x)[f(x) - \sum_{j=0}^n a_j \varphi_j]^2 dx$$

取得极小值。

- 对  $I$  关于  $a_k$  求偏导, 并令偏导数为 0, 得到:

$$\frac{\partial I}{\partial a_k}(a_0, \dots, a_n) = 2 \int_a^b \rho(x)[f(x) - \sum_{j=0}^n a_j \varphi_j] \varphi_k dx = 0.$$

将积分转为内积的形式得到

$$\sum_{j=0}^n a_j \varphi_j \varphi_k$$

2. 由此得到法方程:

$$\begin{bmatrix} (\varphi_0, \varphi_0) & (\varphi_0, \varphi_1) & \cdots & (\varphi_0, \varphi_n) \\ (\varphi_1, \varphi_0) & (\varphi_1, \varphi_1) & \cdots & (\varphi_1, \varphi_n) \\ \vdots & \vdots & \cdots & \vdots \\ (\varphi_n, \varphi_0) & (\varphi_n, \varphi_1) & \cdots & (\varphi_n, \varphi_n) \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ \vdots \\ a_n \end{bmatrix} = \begin{bmatrix} (f, \varphi_0) \\ (f, \varphi_1) \\ \vdots \\ (f, \varphi_n) \end{bmatrix}$$

- 其中  $(\varphi_k, \varphi_j) = \int_a^b \rho(x) \varphi_k(x) \varphi_j(x) dx$ ,  $(f, \varphi_j) = \int_a^b \rho(x) f(x) \varphi_j(x) dx$ 。

### 三、性质与意义

1. 由于  $\varphi_0, \dots, \varphi_n$  线性无关, 所以法方程系数行列式  $G_n \neq 0$ , 法方程有唯一解。这意味着可以确定唯一的最佳平方逼近函数。
2. 平方误差为:

$$\|\delta(x)\|_2^2 = (f - s^*, f - s^*) = (f, f) - (f, s^*) = \|f(x)\|_2^2 - \sum_{k=0}^n a_k^* (f, \varphi_k).$$

# 曲线拟合

## 1. 最小二乘法

最小二乘法是一种曲线拟合方法，用于在给定的数据点集上找到一个最佳的拟合函数。

### 一、误差度量

1. 首先定义误差的不同度量方式，包括

- 无穷范数误差

$$\|\delta\|_{\infty} = \max_i |\delta_i| = \max_i |S(x_i) - f(x_i)|$$

- 1-范数误差

$$\|\delta\|_1 = \sum_{i=0}^n |\delta_i| = \sum_{i=0}^n |S(x_i) - f(x_i)|.$$

- 2-范数误差  $\|\delta\|_2 = (\sum_{i=0}^n \delta_i^2)^{\frac{1}{2}} = \{\sum_{i=0}^n [S(x_i) - f(x_i)]^2\}^{\frac{1}{2}}$

- 其中  $\delta_i = S(x_i) - f(x_i)$  表示在点  $x_i$  处拟合函数  $S(x)$  与实际函数  $f(x)$  的偏差。最小二乘法要求 2-范数误差平方最小，即  $\|\delta\|_2^2 = \sum_{i=0}^n \delta_i^2 = \sum_{i=0}^n [S(x_i) - f(x_i)]^2$  最小。

### 二、一般提法

对于给定的数据  $(x_i, y_i) (i = 0, 1, \dots, m)$ ，要求在给定函数类  $\Phi = \text{span}\{\varphi_0, \dots, \varphi_n\}$  中找一函数  $s^*(x) = \sum_{j=0}^n a_j^* \varphi_j$ ，其中  $n < m$ ，使得  $s^*(x)$  满足

$$\|\delta\|_2^2 = \sum_{i=0}^m \delta_i^2 = \sum_{i=0}^m [s^*(x_i) - f(x_i)]^2 = \min_{s(x) \in \Phi} \sum_{i=0}^m [s(x_i) - f(x_i)]^2$$

### 三、更一般提法

更一般地，要求  $\|\delta\|_2^2 = \sum_{i=0}^m \omega(x_i) \delta_i^2 = \sum_{i=0}^m \omega(x_i) [s^*(x_i) - f(x_i)]^2 = \min_{s(x) \in \Phi} \sum_{i=0}^m \omega(x_i) [s(x_i) - f(x_i)]^2$ ，其中引入了权重函数  $\omega(x_i)$ ，可以根据不同的数据点重要性进行调整。

### 四、问题归结

将最小二乘法问题归结为求  $s(x) = \sum_{k=0}^n a_k \varphi_k(x)$  的系数  $a_k$ ，使得

$$I(a_0, \dots, a_n) = \sum_{i=0}^m \omega(x_i) [\sum_{k=0}^n a_k \varphi_k(x_i) - f(x_i)]^2$$

取得极小值。

引入内积记号

$$(\varphi_k, \varphi_j) = \sum_{i=0}^m \omega(x_i) \varphi_k(x_i) \varphi_j(x_i)$$

和

$$(f, \varphi_j) = \sum_{i=0}^m \omega(x_i) f(x_i) \varphi_j(x_i)$$

### 五、多项式拟合及法方程

常用多项式拟合，即  $\Phi = \text{span}\{\varphi_0, \dots, \varphi_n\} = \text{span}\{1, x, \dots, x^n\}$ ， $s^*(x) = \sum_{k=0}^n a_k^* x^k$ 。此时可以得到法方程为：

$$\begin{bmatrix} \sum \omega_i & \sum \omega_i x_i & \cdots & \sum \omega_i x_i^n \\ \sum \omega_i x_i & \sum \omega_i x_i^2 & \cdots & \sum \omega_i x_i^{n+1} \\ \vdots & \vdots & \cdots & \vdots \\ \sum \omega_i x_i^n & \sum \omega_i x_i^{n+1} & \cdots & \sum \omega_i x_i^{2n} \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ \vdots \\ a_n \end{bmatrix} = \begin{bmatrix} \sum \omega_i y_i \\ \sum \omega_i x_i y_i \\ \vdots \\ \sum \omega_i x_i^n y_i \end{bmatrix}$$

通过求解这个法方程，可以得到多项式拟合的系数  $a_k$ ，从而确定最小二乘解  $s^*(x)$ 。

可以通过线性变换将非线性拟合转化为线性拟合

# 数值积分

+++info imphasis

插值型求积公式的概念，求积系数及相关性质

掌握基本的数值求积公式，中矩形求积公式，梯形求积公式，辛普森公式及对应的复化求积公式

自适应求积的基本思想

掌握龙贝格求积的思想及龙贝格求积公式

针对具体的问题会计算代数精度，会用具体的求积公式进行计算求解

## 1. 插值求积与代数精度

### 一、插值求积

#### 1. 基本概念

- 插值求积是基于插值多项式来近似计算定积分的方法。其核心思想是先利用已知节点上的函数值构造一个插值多项式，然后对这个插值多项式进行积分来近似原函数的定积分。

#### 2. 具体方法

- 设给定区间 $[a, b]$ 上的 $n + 1$ 个节点 $x_0, x_1, \dots, x_n$ 及对应的函数值 $f(x_0), f(x_1), \dots, f(x_n)$ 。
- 通过这些节点构造一个插值多项式 $L_n(x)$ ，使得 $L_n(x_i) = f(x_i)$ ， $i = 0, 1, \dots, n$ 。
- 然后计算插值多项式的积分 $\int_a^b L_n(x)dx$ 作为原函数定积分 $\int_a^b f(x)dx$ 的近似值。

### 二、代数精度

#### 1. 定义

- 若一个数值求积公式对于所有次数不超过 $m$ 的多项式都能准确成立，而对于某个 $m + 1$ 次多项式不成立，则称该求积公式具有 $m$ 次代数精度。

#### 2. 意义

- 代数精度是衡量数值求积公式准确性的一个重要指标。代数精度越高，说明该求积公式在对多项式函数进行积分时的准确性越高。
- 通过确定求积公式的代数精度，可以评估不同求积公式的优劣，为选择合适的求积方法提供依据。

#### 3. 与插值求积的关系

- 对于插值求积法，其代数精度与所使用的插值多项式的次数有关。一般来说，插值多项式的次数越高，插值求积公式的代数精度也越高。
- 例如，梯形公式是基于一次插值多项式的求积公式，其代数精度为 1；辛普森公式是基于二次插值多项式的求积公式，其代数精度为 3。

### 一、插值求积公式的表达式与性质

#### 1. 插值基函数：

• 
$$l_k(x) = \prod_{\substack{j=0 \\ j \neq k}}^n \frac{x - x_j}{x_k - x_j} \quad (k = 0, 1, \dots, n)$$

#### ◦ 插值求积公式定义：

求积公式

$$\int_a^b f(x)dx \approx \sum_{k=0}^n A_k f(x_k)$$

其系数 $A_k = \int_a^b l_k(x)dx$ 时，则称求积公式为插值求积公式。

#### 2. 求积公式推导：

- 对于积分 $\int_a^b l_k(x)dx = \sum_{j=0}^n A_j l_k(x_j)$ ，其中 $l_k(x_j) = \delta_{kj} = \begin{cases} 1 & k = j \\ 0 & k \neq j \end{cases}$ 。
- 取 $f(x) = l_k(x)$ 时， $\int_a^b f(x)dx = \int_a^b l_k(x)dx = \sum_{j=0}^n A_j l_k(x_j)$ ，所以有 $A_k = \int_a^b l_k(x)dx$ ，此时求积公式为插值型求积公式。

### 插值求积公式的余项

1. 余项表达式:

- 设插值求积公式的余项为 $R(f)$ ，由插值余项定理得

$$R(f) = \int_a^b [f(x) - P(x)]dx = \int_a^b \frac{f^{(n+1)}(\xi)}{(n+1)!} \omega(x) dx$$

其中 $\xi \in [a, b]$ 。

2. 当 $f(x)$ 是次数不高于 $n$ 的多项式时， $f^{(n+1)}(x) = 0$ ， $R(f) = 0$ ，求积公式能成为准确的等式。

### 插值型求积公式的充要条件与代数精度

1. 定理:

- $n+1$ 个节点的求积公式 $\int_a^b f(x)dx \approx \sum_{k=0}^n A_k f(x_k)$ 为插值型求积公式的充要条件是公式至少具有 $n$ 次代数精度。

2. 证明:

- 必要性: 若求积公式为插值型求积公式，求积系数为 $A_k = \int_a^b l_k(x)dx$ 。又 $f(x) = P(x) + R(x)$ ，当 $f(x)$ 为不高于 $n$ 次的多项式时， $f(x) = P(x)$ ，其余项 $R(f) = 0$ ，因而这时求积公式至少具有 $n$ 次代数精度。
- 充分性: 若求积公式至少具有 $n$ 次代数精度，则对 $n$ 次多项式

$$l_k(x_j) = \delta_{kj} = \begin{cases} 1 & k=j \\ 0 & k \neq j \end{cases}$$

精确成立。 $f(x) = l_k(x)$ 时， $\int_a^b f(x)dx = \int_a^b l_k(x)dx = \sum_{j=0}^n A_j l_k(x_j)$ ，所以有 $A_k = \int_a^b l_k(x)dx$ ，此时求积公式为插值型求积公式。

**代数精度:** 若求积公式至少具有 $n$ 次代数精度，则对 $n$ 次多项式，可得方程组

$$\begin{cases} A_0 + A_1 + \cdots + A_n = b-a \\ A_0 x_0 + A_1 x_1 + \cdots + A_n x_n = \frac{b^2-a^2}{2} \\ \cdots \cdots \\ A_0 x_0^n + A_1 x_1^n + \cdots + A_n x_n^n = \frac{b^{n+1}-a^{n+1}}{n+1} \end{cases}$$

这是关于 $A_k$ 的线性方程组，其系数矩阵是范德蒙矩阵，当 $x_k (k=0, 1, \cdots, n)$ 互异时非奇异，故 $A_k$ 有唯一解。

### 四、求积系数与定义

$$A_k = \int_a^b l_k(x)dx = \int_a^b \frac{\omega(x)}{(x-x_k)\omega'(x_k)} dx$$

称为求积系数。

## 2. 求积公式

▮ 梯形和中矩形只有1次代数精度，辛普森有3次代数精度

### 一、牛顿-柯特斯公式

1. 梯形公式:

- 对于区间 $[a, b]$ 上的定积分 $\int_a^b f(x)dx$ ，将区间分为两部分，用连接两点 $(a, f(a))$ 和 $(b, f(b))$ 的直线（即梯形的上下底）来近似代替曲线 $f(x)$ ，得到梯形公式:

$$\int_a^b f(x)dx \approx \frac{b-a}{2} [f(a) + f(b)]$$

2. 中矩形公式:

$$\int_a^b f(x)dx \approx (b-a)f\left(\frac{a+b}{2}\right)$$

3. 辛普森公式:

- 将区间 $[a, b]$ 分为三部分，用二次抛物线来近似代替曲线 $f(x)$ 。辛普森公式为:

$$\int_a^b f(x)dx \approx \frac{b-a}{6} [f(a) + 4f\left(\frac{a+b}{2}\right) + f(b)]$$

4. 牛顿-柯特斯公式一般形式：

- 对于  $n+1$  个节点的牛顿-柯特斯公式为， $\int_a^b f(x)dx \approx (b-a) \sum_{k=0}^n C_k^{(n)} f(x_k)$  其中  $C_k^{(n)}$  是柯特斯系数， $x_k = a + k \frac{b-a}{n}$ 。

## 二、高斯型求积公式

1. 基本思想：

- 高斯型求积公式是在积分区间上选取适当的节点和权系数，使得求积公式具有尽可能高的代数精度。

2. 公式形式：

$$\int_a^b f(x)dx \approx \sum_{k=1}^n A_k f(x_k)$$

其中  $x_k$  是求积节点， $A_k$  是求积系数。

代数精度：**插值积分至少有n次精度**

## 3. 复化求积公式

1. 复化梯形公式：

- 将区间  $[a, b]$  分成  $n$  个子区间，在每个子区间上应用梯形公式，然后将结果相加。复化梯形公式为：

$$\int_a^b f(x)dx \approx \frac{h}{2} [f(a) + 2 \sum_{i=1}^{n-1} f(x_i) + f(b)]$$

其中  $h = \frac{b-a}{n}$ ， $x_i = a + ih$ 。

2. 复化辛普森公式：

- 类似地，将区间分成  $n$  个子区间，在每个子区间上应用辛普森公式，然后相加。复化辛普森公式为：

$$\int_a^b f(x)dx \approx \frac{h}{6} [f(a) + 4 \sum_{i=0}^{n-1} f(x_{i+\frac{1}{2}}) + 2 \sum_{i=1}^{n-1} f(x_i) + f(b)]$$

## 4. 低阶求积公式余项

具有n阶代数精度的求积公式都可认为是n阶的插值求积公式

$$R = I - I^* = \int_a^b S - S^* dx = \int_a^b R_s dx = \int_a^b \frac{f^{(n+1)}(\xi)}{(n+1)!} \omega_{n+1}(x) dx$$

### 4.1 梯形公式的余项

1. 梯形公式 (4.1.1) 的余项为

$$R_T = I - T = \int_a^b \frac{f''(\xi)}{2} (x-a)(x-b) dx$$

取的左右端点，做的一阶插值

2. 由于积分的核函数  $(x-a)(x-b)$  在区间  $[a, b]$  上保号（非正），应用积分中值定理，在  $(a, b)$  内存在一点  $\eta$ ，使得

$$R_T = \frac{f''(\eta)}{2} \int_a^b (x-a)(x-b) dx = -\frac{f''(\eta)}{12} (b-a)^3, \quad \eta \in (a, b)$$

### 4.2 Simpson 公式的余项

1. Simpson 公式 (4.2.3) 的余项  $R_S = I - S = \int_a^b [f(x) - H(x)] dx$ ，其中  $H(x)$  是构造的次数不大于三的多项式，满足  $H(a) = f(a)$ ， $H(b) = f(b)$ ， $H(c) = f(c)$ ， $H'(c) = f'(c)$ ， $c = \frac{a+b}{2}$ 。

2. 由于 Simpson 公式具有**三次代数精度**，对于这样构造出的三次式  $H(x)$  是准确的，即

$$\int_a^b H(x) dx = \frac{b-a}{6} [H(a) + 4H(c) + H(b)]，上式右端实际上等于按 Simpson 公式 (4.2.3) 求得的积分值  $S$ 。$$

3. 对于满足条件 (4.2.6) 的多项式  $H(x)$ ，其插值余项

$$f(x) - H(x) = \frac{f^{(4)}(\xi)}{4!} (x-a)(x-c)^2(x-b)，$$

所以

$$R_S = \int_a^b \frac{f^{(4)}(\xi)}{4!} (x-a)(x-c)^2(x-b) dx$$

4. 积分核 $(x-a)(x-c)^2(x-b)$ 在 $[a, b]$ 上保号（非正），用积分中值定理有

$$R_S = \frac{f^{(4)}(\eta)}{4!} \int_a^b (x-a)(x-c)^2(x-b)dx = -\frac{b-a}{180} \left(\frac{b-a}{2}\right)^4 f^{(4)}(\eta)$$

## 4.3 Cotes 公式的余项

1. Cotes 公式 (4.2.4) 的积分余项仅列出结果为 $R_C = I - C = -\frac{2(b-a)}{945} \left(\frac{b-a}{4}\right)^6 f^{(6)}(\eta)$ 。

## 4.4 复化梯形余项

$$R_n = I - T_n = -\frac{b-a}{12} \left(\frac{b-a}{n}\right)^2 f''(\xi)$$

## 4.5 复化辛普森余项

$$R_n = -\frac{b-a}{180} (h)^4 f^{(4)}(\xi), \quad h = \frac{b-a}{n}$$

# 5. 自适应求积

### 一、基本思想

1. 从一个较粗的积分步长开始，计算积分的近似值。
2. 然后将**积分步长减半，再次计算积分近似值**。
3. 比较两次计算结果的差异，如果差异较大，则继续减小步长进行计算，直到满足一定的精度要求。

### 二、变步长梯形公式

1. 首先用梯形公式计算积分的近似值：

- 对于区间 $[a, b]$ 上的定积分 $\int_a^b f(x)dx$ ，梯形公式为 $T(h) = \frac{h}{2}[f(a) + f(b)] + \sum_{i=1}^{n-1} h f(x_i)$ ，其中 $h = \frac{b-a}{n}$ ， $x_i = a + ih$ 。

2. 将步长减半，得到新的近似值：

- 令 $h' = \frac{h}{2}$ ，新的梯形公式为 $T(h') = \frac{h'}{2}[f(a) + f(b)] + \sum_{i=1}^{2n-1} h' f(x'_i)$ 。

3. 计算两次近似值的差异：

- 可以得到

$$T_{2n} = \frac{1}{2}T_n + \frac{h}{2} \sum_{i=1}^n f(x_{i+\frac{1}{2}})$$

### 三、变步长辛普森公式

1. 类似地，可以从辛普森公式出发，逐步减小步长进行计算。

辛普森公式为

$$S(h) = \frac{h}{6}[f(a) + f(b) + 4 \sum_{i=1}^{n-1} f(x_{2i-1}) + 2 \sum_{i=1}^{n-1} f(x_{2i})]$$

2. 递推公式为

$$S_{2n} = \frac{S_n}{2} + \frac{h}{4} \sum_{i=0}^{n-1} \left[ f(x_{2i+\frac{1}{2}}) + f(x_{2i+\frac{3}{2}}) \right]$$

# 6. Romberg 算法

龙贝格

龙贝格算法是一种用于数值积分的高效方法，以下是对图片内容的整理：

### 一、龙贝格算法计算步骤

1. 按变步长梯形公式计算积分近似值：

- 对于区间 $[a, b]$ ，先进行区间划分，区间长度 $h = \frac{b-a}{n}$  ( $n = 2^k$ )。

- 变步长梯形公式为  $T_{2n} = \frac{T_n}{2} + \frac{h}{2} \sum_{k=0}^{n-1} f(x_{k+\frac{1}{2}})$ , 其中  $x_{k+\frac{1}{2}} = a + (k + \frac{1}{2})h$ 。

2. 按加速公式求加速值:

- 梯形公式加速:  $S_n = T_{2n} + \frac{T_{2n}-T_n}{3}$  (此处以整理后的正确公式为准, 图片中可能有误)。
- Simpson 加速公式:  $C_n = S_{2n} + \frac{S_{2n}-S_n}{15}$ 。
- 龙贝格求积公式:  $R_n = C_{2n} + \frac{C_{2n}-C_n}{63}$ 。

## 二、公式推导过程

1. 从柯特斯公式的误差公式进一步导出龙贝格公式:  $R_n = \frac{64}{63}C_{2n} - \frac{1}{63}C_n$ 。
2. 考察 Simpson 法, 其截断误差与  $h^4$  成正比, 若将步长折半, 则误差减至  $\frac{1}{16}$ , 即  $\frac{I-S_{2n}}{I-S_n} \approx \frac{1}{16}$ , 由此可得  $I = \frac{16}{15}S_{2n} - \frac{1}{15}S_n$ , 可以验证上式右端的值等于  $C_n$ , 即  $C_n = \frac{16}{15}S_{2n} - \frac{1}{15}S_n$ 。
3. 用梯形法二分前后两个积分值  $T_n$  和  $T_{2n}$  作线性组合, 可得到复化 Simpson 公式计算得到的积分值  $S_n$ , 即  $S_n = \frac{4}{3}T_{2n} - \frac{1}{3}T_n$ 。

## 三、精度控制

直到相邻两次积分值  $|R_{2n} - R_n| < \varepsilon$  (其中  $\varepsilon$  为允许的误差限), 则终止计算并取  $R_n$  作为积分的近似值。

龙贝格算法通过变步长将粗糙的梯形值逐步加工成精度较高的 Simpson 值、柯特斯值和龙贝格值, 将收敛缓慢的梯形值序列加工成收敛迅速的龙贝格值序列。

#

1. 计算向量  $x = (1, -2, 3)^T$  的各种范数 `{.gap}{.quiz .fill}`

$$\|x\|_1 = 6, \|x\|_\infty = 3, \|x\|_2 = \sqrt{14}$$

2. 题目: 设  $f(x) = \sqrt{1+x^2}$ , 求在区间  $[0, 1]$  上的一次最佳平方逼近多项式。

解析:

1. 首先计算内积:

- $(f, \varphi_0) = \int_0^1 \sqrt{1+x^2} dx = \frac{1}{2} \ln(1+\sqrt{2}) + \frac{\sqrt{2}}{2} \approx 1.147$ 。
- $(f, \varphi_1) = \int_0^1 x \sqrt{1+x^2} dx = \frac{1}{3} (1+x^2)^{\frac{3}{2}} \Big|_0^1 = \frac{2\sqrt{2}-1}{3} \approx 0.609$ 。

2. 得到方程组:

$$\begin{bmatrix} 1 & 1/2 \\ 1/2 & 1/3 \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \end{bmatrix} = \begin{bmatrix} 1.147 \\ 0.609 \end{bmatrix}.$$

3. 解方程组得:  $a_0 = 0.934, a_1 = 0.426$ 。

- 故一次最佳平方逼近多项式为  $S_1^*(x) = 0.934 + 0.426x$ 。

4. 计算平方误差:

$$\|\delta(x)\|_2^2 = (f(x), f(x)) - (S_1^*(x), f(x)) = \int_0^1 (1+x^2) dx - 0.426d_1 - 0.934d_0 = 0.0026, \text{ 其中 } d_0 = (S_1^*(x), \varphi_0), d_1 = (S_1^*(x), \varphi_1).$$

5. 计算最大误差:

$$\|\delta(x)\|_\infty = \max_{0 \leq x \leq 1} |\sqrt{1+x^2} - S_1^*(x)| \approx 0.066.$$

3. 试确定一个至少具有 2 次代数精度的公式  $\int_0^4 f(x) dx \approx Af(0) + Bf(1) + Cf(3)$ 。

- 解: 要使公式具有 2 次代数精度, 则对  $f(x) = 1, x, x^2$  求积公式准确成立, 即得方程组 
$$\begin{cases} A+B+C=4 \\ B+3C=8 \\ B+9C=\frac{64}{3} \end{cases}, \text{ 解得}$$

$$A = \frac{14}{3}, B = \frac{4}{3}, C = \frac{8}{3}. \text{ 因此, 所求公式为 } \int_0^4 f(x) dx \approx \frac{14}{3}f(0) + \frac{4}{3}f(1) + \frac{8}{3}f(3).$$



4. 试确定求积系数 A、B、C 使  $\int_{-1}^1 f(x)dx \approx Af(-1) + Bf(0) + Cf(1)$  具有最高的代数精度。

○ 解：分别取  $f(x) = 1, x, x^2$  使求积公式准确成立，即得 
$$\begin{cases} A + B + C = 2 \\ -A + C = 0 \\ A + C = \frac{2}{3} \end{cases}, \text{ 所得求积公式为}$$

$\int_{-1}^1 f(x)dx \approx \frac{1}{3}f(-1) + \frac{4}{3}f(0) + \frac{1}{3}f(1)$ 。可验证该求积公式对于  $f(x) = 1, x, x^2, x^3$  都准确成立，对于  $f(x) = x^4$  不能准确成立，所以求积公式具有 3 次代数精度。

5. 考察求积公式  $\int_{-1}^1 f(x)dx \approx \frac{1}{2}[f(-1) + 2f(0) + f(1)]$  的代数精度。

○ 解：可以验证，对于  $f(x) = 1, x$  时，公式两端相等；再将  $f(x) = x^2$  代入公式，左端为  $\int_{-1}^1 x^2 dx = \frac{2}{3}$ ，右端为  $\frac{1}{2}[f(-1) + 2f(0) + f(1)] = \frac{1}{2}[1 + 1] = 1$ ，左端不等于右端，所以求积公式具有 1 次代数精度。且三个节点不一定具有 2 次代数精度，因为不是插值型的。

6. 给定求积式  $\int_0^1 f(x)dx \approx \frac{1}{3}[2f(\frac{1}{4}) - f(\frac{1}{2}) + 2f(\frac{3}{4})]$ ，求证此求积公式是插值型求积公式。

解：

○ 首先计算插值基函数：

$$\begin{aligned} \blacksquare l_0(x) &= (x - \frac{1}{2})(x - \frac{3}{4}) / (\frac{1}{4} - \frac{1}{2})(\frac{1}{4} - \frac{3}{4}) = 8(x - \frac{1}{2})(x - \frac{3}{4}). \\ \blacksquare l_1(x) &= (x - \frac{1}{4})(x - \frac{3}{4}) / (\frac{1}{2} - \frac{1}{4})(\frac{1}{2} - \frac{3}{4}) = -16(x - \frac{1}{4})(x - \frac{3}{4}). \\ \blacksquare l_2(x) &= (x - \frac{1}{4})(x - \frac{1}{2}) / (\frac{3}{4} - \frac{1}{4})(\frac{3}{4} - \frac{1}{2}) = 8(x - \frac{1}{4})(x - \frac{1}{2}). \end{aligned}$$

○ 然后计算积分：

$$\begin{aligned} \blacksquare \int_0^1 l_0(x)dx &= 8 \int_0^1 (x^2 - \frac{5}{4}x + \frac{3}{8})dx = 8(\frac{1}{3} - \frac{5}{4} \times \frac{1}{2} + \frac{3}{8}) = \frac{8}{3} - 2 = \frac{2}{3}. \\ \blacksquare \int_0^1 l_1(x)dx &= (-16) \int_0^1 (x^2 - x + \frac{3}{16})dx = (-16)(\frac{1}{3} - \frac{1}{2} + \frac{3}{16}) = \frac{16}{6} - 3 = -\frac{1}{3}. \\ \blacksquare \int_0^1 l_2(x)dx &= 8 \int_0^1 (x^2 - \frac{3}{4}x + \frac{1}{8})dx = 8(\frac{1}{3} - \frac{3}{4} \times \frac{1}{2} + \frac{1}{8}) = \frac{8}{3} - 2 = \frac{2}{3}. \end{aligned}$$

○ 由插值型求积公式的定义知，所给的求积公式是插值型求积公式。

7. 题目：

计算定积分  $I = \int_0^1 \ln x dx$ ，依次用  $n = 8$  的复化梯形公式和  $n = 4$  的复化 Simpson 公式进行计算。

解：

1. 当  $n = 8$  时：

$$\blacksquare h = \frac{1}{8} = 0.125.$$

■ 由复化梯形公式可得计算公式：

$$T_8 = \frac{1}{16}[f(0) + 2f(0.125) + 2f(0.25) + 2f(0.375) + 2f(0.5) + 2f(0.625) + 2f(0.75) + 2f(0.875) + f(1)] = 0.9456909$$

。

2. 当  $n = 4$  时：

■ 由复化 Simpson 公式可得计算公式：

$$S_4 = \frac{1}{24}[f(0) + f(1) + 2(f(0.25) + f(0.5) + f(0.75)) + 4(f(0.125) + f(0.375) + f(0.625) + f(0.875))] = 0.9460832$$

。

3. 积分准确值  $I = 0.9460831$ 。

4. 两种方法都需要提供 9 个点上的函数值，计算量基本相同，但精度差别较大。与积分准确值比较，复化梯形公式只有两位有效数字，而复化 Simpson 公式却有六位有效数字。

8. 题目：

用变步长梯形求积公式计算定积分  $I = \int_0^1 \frac{\sin x}{x} dx$ 。

解：

1. 先对整个区间  $[0, 1]$  用梯形公式：

$$\blacksquare \text{ 已知 } f(x) = \frac{\sin x}{x}, f(0) = 1, f(1) = 0.8410709.$$

$$\blacksquare \text{ 所以 } T_1 = \frac{1}{2}[f(0) + f(1)] = 0.9207355.$$

2. 然后将区间二等分：

$$\blacksquare \text{ 由于 } f(\frac{1}{2}) = 0.958851, \text{ 故有 } T_2 = \frac{1}{2}T_1 + \frac{1}{2}f(\frac{1}{2}) = 0.9397933.$$

3. 进一步二分求积区间，并计算新分点上的函数值：

$$\blacksquare f(\frac{1}{4}) = 0.9896158, f(\frac{3}{4}) = 0.9088516.$$

$$\blacksquare \text{ 有 } T_4 = \frac{1}{2}T_2 + \frac{1}{4}[f(\frac{1}{4}) + f(\frac{3}{4})] = 0.9445135.$$

4. 这样不断二分下去，积分准确值为 0.9460831，从计算结果表中可看出用变步长二分 10 次可得此结果。

9. 题目：用龙贝格算法计算定积分  $I = \int_0^1 \frac{4}{1+x^2} dx$ ，要求相邻两次龙贝格值的偏差不超过  $10^{-5}$ 。

解：

$$1. \text{ 已知 } a = 0, b = 1, f(x) = \frac{4}{1+x^2}.$$

2. 首先计算梯形值:

- $T_1 = \frac{1}{2}[f(0) + f(1)] = \frac{1}{2}(4 + 2) = 3。$
- $T_2 = \frac{1}{2}T_1 + \frac{1}{2}f(\frac{1}{2}) = \frac{1}{2} \times 3 + \frac{1}{2} \times \frac{16}{5} = 3.1。$
- $T_4 = \frac{1}{2}T_2 + \frac{1}{4}[f(\frac{1}{4}) + f(\frac{3}{4})] = \frac{1}{2} \times 3.1 + \frac{1}{4}(3.764 + 2.56) = 3.13118。$
- $T_8 = \frac{1}{2}T_4 + \frac{1}{8}[f(\frac{1}{8}) + f(\frac{3}{8}) + f(\frac{5}{8}) + f(\frac{7}{8})] = 3.13899。$
- $T_{16} = \frac{1}{2}T_8 + \frac{1}{16}[f(\frac{1}{16}) + f(\frac{3}{16}) + f(\frac{5}{16}) + f(\frac{7}{16}) + f(\frac{9}{16}) + f(\frac{11}{16}) + f(\frac{13}{16}) + f(\frac{15}{16})] = 3.1409。$

3. 然后计算 Simpson 值:

- $S_1 = \frac{4}{3}T_2 - \frac{1}{3}T_1 = 3.1333。$
- $S_2 = \frac{4}{3}T_4 - \frac{1}{3}T_2 = 3.14157。$
- $S_4 = \frac{4}{3}T_8 - \frac{1}{3}T_4 = 3.14159。$
- $S_8 = \frac{4}{3}T_{16} - \frac{1}{3}T_8 = 3.14159。$

4. 接着计算柯特斯值:

- $C_1 = \frac{16}{15}S_2 - \frac{1}{15}S_1 = 3.14212。$
- $C_2 = \frac{16}{15}S_4 - \frac{1}{15}S_2 = 3.14159。$
- $C_4 = \frac{16}{15}S_8 - \frac{1}{15}S_4 = 3.14159。$

5. 最后计算龙贝格值:

- $R_1 = \frac{64}{63}C_2 - \frac{1}{63}C_1 = 3.14158。$
- $R_2 = \frac{64}{63}C_4 - \frac{1}{63}C_2 = 3.14159。$

6. 由于  $|R_2 - R_1| \leq 0.00001$ , 于是有  $I = \int_0^1 \frac{4}{1+x^2} dx \approx 3.14159。$